

扫地机器人 RAG 项目 召回率评测报告

评测日期：2026-08-28 | 数据来源：eval_set.json (2474 条) + retrieval_20260828_144102.json (抽样 100 条)

一、项目与评测背景

本项目是“扫地/扫拖一体机器人智能客服 RAG 系统”：用户问题先经查询改写，再走混合检索（稠密向量 Chroma + BM25 稀疏 + RRF 融合），最后把检索结果拼进提示词交给大模型生成回答。召回率决定“资料是否捞全”，是 RAG 链路的核心指标，直接决定生成质量的上界。

评测集由 build_eval_set.py 自动构建：共 2474 条（原版 1237 + 同义变体 1237），覆盖 qa 问答 400、fault 故障 400、knowledge 知识 1674 三类，每类都包含原版与“换说法”变体，用于检验检索对同义改写是否敏感。本次评测抽样 100 条。

二、评测方法

2.1 四组检索策略（考生）

dense：纯稠密，query 向量化后在 Chroma 里按语义相似度取 Top-20。

bm25：纯稀疏，jieba 分词 + BM25 关键词打分取 Top-20。

hybrid：稠密 + 稀疏两路召回，用 RRF 公式 $1/(k+rank)$ 融合排序。

hybrid_rewrite：先由 LLM 把问题改写成多条查询，再走混合检索。

2.2 黄金标准（gold）

对每条评测题，用标准答案（answer）去向量库 866 个分块里匹配：先按句拆段逐段找，找不到再按最长前缀回退；命中分块的正文 md5 组成该题的相关分块集合 gold。检索返回的分块也转成 md5 列表，与 gold 比对即可算分。

2.3 指标口径

指标	含义
recall@5 / recall_full	召回率：前5名 / 整批候选里捞回的相关分块比例
hit@5	前5名是否出现正确答案 (0/1)
mrr@10	第一个正确答案的排名倒数均值
ndcg@10	整体排序质量
context_precision@5	前5名中相关内容的占比（精确率）
avg_ms	平均检索耗时

三、评测结果

3.1 总体指标（100 条抽样）

策略	hit@5	recall@5	mrr@10	ndcg@10	cp@5	recall_full	avg_ms
dense	0.63	0.63	0.5496	1.1108*	0.5422	0.80	591.9
bm25	0.71	0.71	0.6422	1.2079*	0.6484	0.86	3.4

hybrid	0.82	0.82	0.5911	0.67	0.5752	0.94	635.4
hybrid_rewrite	0.86	0.86	0.6438	0.7127	0.6347	0.95	3765.6

* ndcg@10 出现大于 1 的异常值：语料中存在内容完全相同的重复分块，dense/bm25 策略未去重导致 NDCG 被重复计数，该列暂不可采信。

3.2 按 类型/原版变体 分组 (recall@5 / recall_full / cp@5)

策略	分组	recall@5	recall_full	cp@5
dense	qa/original	0.80	0.90	0.495
dense	fault/original	0.60	1.00	0.600
dense	knowledge/original	0.55	0.725	0.482
dense	qa/variant	0.778	0.889	0.633
dense	fault/variant	0.50	1.00	0.500
dense	knowledge/variant	0.656	0.781	0.603
bm25	qa/original	0.90	1.00	0.800
bm25	fault/original	1.00	1.00	1.000
bm25	knowledge/original	0.65	0.825	0.597
bm25	qa/variant	0.778	0.889	0.778
bm25	fault/variant	0.75	0.75	0.563
bm25	knowledge/variant	0.656	0.844	0.585
hybrid	qa/original	0.70	1.00	0.160
hybrid	fault/original	0.60	1.00	0.120
hybrid	knowledge/original	0.90	0.90	0.733
hybrid	qa/variant	0.444	1.00	0.115
hybrid	fault/variant	0.50	1.00	0.113
hybrid	knowledge/variant	0.938	0.938	0.766
hybrid_rewrite	qa/original	0.80	1.00	0.270
hybrid_rewrite	fault/original	0.80	1.00	0.250
hybrid_rewrite	knowledge/original	0.875	0.925	0.751
hybrid_rewrite	qa/variant	0.778	1.00	0.278
hybrid_rewrite	fault/variant	0.75	1.00	0.175
hybrid_rewrite	knowledge/variant	0.906	0.938	0.821

样本分布：knowledge 组 72 条（原版 40 + 变体 32）、qa 组 19 条（10+9）、fault 组仅 9 条（5+4）。fault 组样本过小，其数字（如 0.5、0.6）基本是噪声，不建议单独下结论。

四、结果分析

4.1 混合检索是否更好

结论：在这套更大、更难（含变体与知识类）的评测集上，混合检索确实更好。hybrid_rewrite 的 recall@5 0.86、recall_full 0.95 全面优于单路 dense（0.63/0.80）与 bm25（0.71/0.86）。

但提升主要来自 knowledge 类问题：hybrid 在 knowledge 组 recall@5 达 0.90~0.94、cp@5 达 0.73~0.77；而 qa/fault 短问答组，hybrid 的 cp@5 仍只有 0.11~0.27，说明融合对短问答仍会把正确分块稀释到后排。

4.2 召回率水平解读

recall_full 0.94~0.95 说明答案基本都被捞到（整批候选内）；recall@5 0.82~0.86 说明前 5 名仍有提升空间。二者落差意味着下一步应聚焦“重排”（rerank），把捞到的正确答案提到前排。

4.3 需要修的问题

NDCG>1 异常：语料含重复分块，dense/bm25 未去重导致指标失真，需在策略层去重或修指标。

fault 组样本量太小（4~5 条），结论置信度低，需加大 fault 抽样。

变体组普遍低于原版组，说明检索对同义改写敏感，这是真实短板。

五、面试问答（召回率相关）

问题	参考回答要点
Q1 什么是召回率？和精确率有什么区别？	召回率 = 检索结果中命中的相关分块数 / 全部相关分块数，衡量捞得全不全；精确率 = 命中数 / 检索结果总数，衡量捞得准不准。两者是一对跷跷板。
Q2 你项目里召回率怎么算的？	先用标准答案在语料分块里匹配生成 gold（相关分块 md5 集合），再对四种策略算 Recall@5 和整批 recall_full。评测集自动构建 2400+ 条，分 qa/fault/knowledge 三类，并含同义变体。
Q3 你的召回率多少？怎么解读？	融合+改写策略 recall@5 约 0.86、recall_full 约 0.95。recall_full 高说明捞得全，recall@5 说明前 5 名还有空间，下一步做重排。
Q4 为什么用混合检索？RRF 是什么？	稠密抓语义、BM25 抓关键词，互补。RRF 用 $1/(k+rank)$ 融合两路排名。实测发现融合在短问答上会把正确分块稀释到后排（cp@5 掉到 0.1~0.2），所以评测里专门用 context_precision 盯这个问题。
Q5 怎么提升召回率？	四个方向：查询改写加门控、调 RRF 参数（rrf_k/top_n）并给稀疏路加权、优化分块（chunk_size/overlap）、检索后加重排（cross-encoder）。
Q6 gold 怎么来的？有什么坑？	用标准答案在语料分块里做拆段/最长前缀匹配，命中分块的 md5 就是 gold。坑是自动派生对语义等价但字面不同的答案会漏判，需人工标注权威子集校准。
Q7 召回率和生成质量什么关系？	召回是生成的上界：检索漏了，大模型再强也答不出缺失信息。所以 RAG 先保召回，再用精确率和排序控制噪声。

六、召回率优化方向

- 修复评测可信度：去除语料重复分块（修 NDCG>1），加大 fault 组样本，先让数字可信再谈优化。
- 重排（rerank）：recall_full 0.95 vs recall@5 0.86 的落差，正好用 cross-encoder 把正确答案提到前排。
- 查询改写门控：只对口语化/指代/长尾问题改写，避免把“机器人”改成“计算机”这类噪声。
- RRF 参数与加权：调小 rrf_k、减小 top_n、给更强的 BM25 路加权，缓解短问答前排稀释。
- 分块优化：加大 chunk_overlap 或按语义切块，减少答案跨块漏召回。

6. 查询扩展：利用项目已有的术语词典.txt 构建同义词扩展表，直接提升变体组召回。
7. 按类型自适应策略：knowledge 类 hybrid 明显更好，短问答可优先 BM25，做策略分流。

七、附录：数据来源与复现命令

评测集：eval/eval_set.json (build_eval_set.py 生成, 2474 条)

结果文件：eval/results/retrieval_20260828_144102.json (run_retrieval_eval.py --sample 100)

复现：python eval/build_eval_set.py ; python eval/validate_gold.py ; python eval/run_retrieval_eval.py --sample 100